Mathematical Statistics

Velen Kong

2019年8月7日

摘要

出于下学期的课程以及数学建模的需要,只好暑假自学数理统计,自 学首选课本为

韦来生.著. 数理统计(第二版) [M] 北京:科学出版社 2015

由于本人水平限制,大概率不会涉及以下参考资料

陈希孺.著. 高等数理统计学 [M] 合肥:中国科学技术大学出版社 2009

- (美) Hogg R.V. & Craig A.T.著. Introduction to Mathematical Statistics:Fifth Edition 数理统计学导论:第5版(影印版)[M] 北京:高等教育出版社 2004
- (美) Casella G. & Berger R.L.著. Statistical Inference 统计推断(原书第二版) [M] 张忠占 & 傅莺莺.译. 北京:机械工业出版社 2009

1 绪论及预备知识

几个基本概念,总体(population),个体(individual),样本(sample),抽样(sampling),随机变量(random variable),观察值(observation)。总体又分为有限总体(finite population)和无限总体(infinite population)。

然后又有样本空间(sample space),简单随机样本,联合分布函数和联合密度函数

$$F(x_1,\ldots,x_n)=\prod_{i=1}^n F(x_i)$$

$$f(x_1, \dots, x_n) = \prod_{i=1}^n f(x_i)$$

对于多维样本同样有

$$F(X,Y) = \prod_{i=1}^{n} F(x_i, y_i)$$

$$f(X,Y) = \prod_{i=1}^{n} f(x_i, y_i)$$

确定统计模型(statistical model)后,从总体中抽取一定的样本来推断 总体模型被称为统计推断(statistical inference)。需要估计的是参数向量(parameter vector),参数的取值范围就是参数空间(parameter space)。除此以外还有未 知样本分布的非参数统计推断。

而由于参数的不确定性,统计模型是一个样本分布族(distribution family of the sample)。

统计量(statistic)则是样本算出的值,例如样本均值(mean)和方差(variance)。 下面介绍均值和方差的推广——样本矩(sample moments)。

设 X_1, \ldots, X_n 是总体中抽取的样本,则称

$$a_{n,k} = \frac{1}{n} \sum_{i=1}^{n} X_i^k, \qquad k = 1, 2, \dots$$

为样本k阶原点矩。

$$m_{n,k} = \frac{1}{n} \sum_{i=1}^{n} (X_i - \overline{X})^k$$

为样本k阶中心矩。

对于二维总体而言,称

$$S_{XY} = \frac{1}{n} \sum_{i=1}^{n} (X_i - \overline{X})(Y_i - \overline{X})$$

为X和Y的样本协方差(sample covariance)。

然后我们介绍次序统计量(order statistics)。将 X_1, \ldots, X_n 按递增次序排列为 $X_{(1)}, \ldots, X_{(n)}$ 就是样本的次序统计量。

利用次序统计量可以定义样本中位数(sample median),样本极值(extremum of sample),样本p分位数(sample p-fractile),样本极差(sample range)。其中p分位数定义为 $X_{(m)}$, m=[(n+1)p]。

3

样本变异系数(sample coefficient of variation)则是对于总体变异系数(population coefficient of variation)的估计。总体变异系数衡量总体分布的散布程度,定义为

$$\nu = \frac{SD(X)}{E(X)}$$

而样本变异系数则为

$$\nu = \frac{S_n}{\overline{X}}$$

样本偏度(sample skewness)反映了总体偏度的信息,定义是

$$\beta_1 = \frac{\mu_3}{\mu_2^{3/2}}$$

其中正态分布的偏度为0。

而样本偏度则定义为

$$\hat{\beta_1} = \frac{m_{n,3}}{m_{n,2}^{3/2}}$$

样本峰度(sample kurtosis)则是用来反映总体峰度的信息,总体峰度表示密度函数在最大值附近的集中程度,正态分布的峰度为0。总体峰度定义为

$$\beta_2 = \frac{\mu_4}{\mu_2^2} - 3$$

而样本峰度则定义为

$$\hat{\beta}_2 = \frac{\mu_4}{\mu_2^2} - 3$$

接下来介绍经验分布函数,对于一组次序统计量,我们定义

$$F_n(x) = \begin{cases} 0, & x \le X_{(1)}, \\ \frac{k}{x}, & X_{(k)} < x \le X_{(k+1)} \\ 1, & X_{(n)} < x \end{cases}$$

为经验分布函数(empirical distibution function)。易见经验分布函数是 单调不减左连续的,它可以看作总体分布函数的一个估计量。

若记示性函数为

$$I_A(x) = \begin{cases} 1, & x \in A \\ 0, & others \end{cases}$$

那么 $F_n(x)$ 可以表示为

$$F_n(x) = \frac{1}{n} \sum_{i=1}^n I_{(-\infty,x)}(X_i)$$

所以有

$$nF_n(x) = \sum_{i=1}^n Y_i \ b(n, F(x))$$

由中心极限定理当 $n \to \infty$ 时有

$$\frac{\sqrt{n}(F_n(x) - F(x))}{\sqrt{F_n(x) - F(x)}} \stackrel{\mathcal{L}}{\to} N(0, 1)$$

其中△表示依分布收敛。

又由Bernoulli大数定律得

$$F_n(x) \stackrel{P}{\to} F(x) \qquad n \to \infty$$

由Borel大数定律得

$$P(\lim_{n\to\infty} F_n(x) = F(x)) = 1$$

更进一步,有下列格里汶科定理(Glivenko-Cantelli Theorem)。

定理设F(x)为r.v. X的分布函数, $\{X_i\}$ 为简单随机样本, $F_n(x)$ 为其经验分布函数,记 $D_n=\sup_{-\infty< x<+\infty}|F_n(x)-F(x)|$,则有

$$P(\lim_{n\to\infty} D_n = 0) = 1$$

其表明在n足够大时,对于所有的x,经验分布函数的误差都很小。

2 抽样分布 5

2 抽样分布

- 2.1 正态分布
- 2.2 次序统计量
- 2.3 χ^2 分布
- **2.4** *t*分布
- **2.5** F分布
- 2.6 重要推论
- 2.7 极限分布
- 2.8 指数族
- 2.9 充分统计量
- 2.10 完全统计量

3 点估计